
EasyCGTree
An Easy Tool for Constructing Core-Gene Tree
Version 5.0

含图形界面 EasyCGTree_GUI 1.0

Dao-Feng Zhang

更新于 2026 年 10 月 9 日

如有建议或问题，请联系：zdf1987@163.com

目录

1. EasyCGTree 简介.....	1
1.1 基本概念.....	1
2. 如何安装 EasyCGTree?	2
2.1 下载.....	2
2.2 软件包内容.....	2
2.3 Perl 及 EasyCGTree 调用的程序.....	3
2.4 首次启动.....	3
2.5 从源代码运行或编译 EasyCGTree_GUI (可选)	3
3. 输入数据.....	4
3.1 基因组数据 (FASTA 格式)	4
3.2 Profile HMM.....	4
4. 使用图形界面运行 EasyCGTree.....	5
4.1 主窗口.....	5
4.2 主流程: 快速开始.....	6
4.3 主流程: 任务与参数.....	6
4.4 SNP 分析.....	7
4.5 HMM 构建.....	7
4.6 设置.....	7
5. 在命令行中运行 EasyCGTree.....	7
5.1 用法.....	7
5.2 EasyCGTree.pl 的参数 (顺序不限)	8
5.3 关于 '-genome_cutoff' 和 '-gene_cutoff' 的更多说明.....	10
5.4 建树程序的参数.....	11
6. 输出文件.....	11
7. 其他脚本.....	11
7.1 EasyCGTree_SNP.pl.....	12
7.2 EasyCGTree_SpecificSNP.pl.....	12
7.3 BuildHMM.pl.....	13
7.4 Gene_Prevelence.pl.....	13
8. 硬件要求.....	14
9. 常见问题.....	14
10. 引用.....	15
11. 参考文献.....	15

1. EasyCGTree 简介

EasyCGTree 是一款基于基因组数据构建最大似然（ML）系统发育树（即 phylogenomics）的“管道式”分析软件，以 FASTA 格式的微生物基因组数据（氨基酸和/或 DNA 序列）作为输入。软件包内置了预先构建好的核心基因集的隐马尔可夫模型谱（profile HMM），由 HMMER (<http://hmmer.org/>)^[1] 进行同源基因检索；用户也可以使用自己的基因集（以基因簇形式准备，即每个文件包含一个基因的同源序列）构建 profile HMM 并用于检索和建树。EasyCGTree 提供三种建树方法：**超矩阵法（supermatrix）**、**超树法（supertree）**^[2] 和**一致树法（consensus tree）**。从输入的基因组数据到最终的树文件，所有步骤都整合在一套流程中，使构建核心基因树变得十分简单。此外，EasyCGTree 运行产生的中间数据也可以直接导入其他许多软件进行分析。

5.0 版的主要更新如下：

- 1) **EasyCGTree_GUI**：适用于 Windows、Linux 和 macOS 的图形界面，无需使用命令行。界面会显示实际运行的命令，可复制到终端中直接使用。
- 2) **支持 macOS**。在 GitHub 和 Gitee 上为 Windows、Linux 和 macOS（Apple 芯片和 Intel）分别提供可直接使用的软件包。
- 3) 将 CDS 预测分析单独设置（-task predict），可在不重复预测的情况下尝试多个 HMM 集；可直接使用 NCBI 注释文件（CDS 的蛋白和核酸序列）作为输入数据。
- 4) 可基于核心基因**核酸**比对建树（-seq nucl），以及 **SNP 分析**，应用场景扩展到种以下水平：核心基因组 SNP 和 SNP 树（EasyCGTree_SNP.pl），以及树上菌株和分支特异的 SNP（EasyCGTree_SpecificSNP.pl）统计。
- 5) 所有结果可输出到任意文件夹（-outdir）；脚本可在任意目录下调用；每个任务的设置都会被记录，后续任务会检查是否与前面的结果一致，减少不必要的重复运算。
- 6) 更新第三程序：HMMER 3.4、MUSCLE v5、IQ-TREE 3 等。

1.1 基本概念

下面简要解释本手册中的一些术语，供初次使用的用户参考：

术语	含义
核心基因	在一个类群的（几乎）所有基因组中都存在、通常为单拷贝的基因。通过比较这些基因的序列来构建系统发育树。
Profile HMM / HMM 集	由一个基因家族的许多序列构建的统计模型。即使序列差异较大，HMMER 也能用它在基因组中找到该基因的同源序列。一个 HMM 集（如 bac120）包含每个核心基因的模式。
E 值	期望值：在随机情况下，预期出现得分不低于该匹配的结果的数目；数值越小，匹配结果越可靠。E 值大于 'evalue' 的匹配结果会被忽略。
基因组阈值 / 基因阈值	对数据的筛选：检出基因太少的基因组和在太少基因组中检出的基因会被剔除（第 5.3 节）。
比对 / 修剪	将一个基因的各条序列比对，使同源位点位于同一列。修剪会去除不可靠的列（如空位很多的列）。
超矩阵（sm）	将所有基因的比对串联成一个长比对，据此构建一棵树。快速、稳健，为默认方法。
超树（st） / 一致树（cs）	为每个基因构建一棵树，再整合各基因树（st：用 ASTRAL；cs：多数一致树）以得到更可靠的进化树（物种树）。同时也可用于考察各基因之间是否一致。
最大似然（ML）树	在给定的序列进化模型下，使观察到的比对出现概率最大的树（FastTree、IQ-TREE）。

术语	含义
支持率	树上各分支处的数值（如自举值或 SH 类支持率，0-1 或 0-100），表示数据对该分组的支持程度。数值低说明该分支不确定。
Newick	常用的树文件文本格式，如 '((A,B),C);'，可用 FigTree、MEGA、iTOL 等软件打开。
根 / 外群	建树程序得到的是无根树。树的根（最早的分歧点）通过外群确定：外群是确定位于目标类群之外的菌株（第 7.2 节）。
SNP / 核心 SNP	单核苷酸多态性：比对中各菌株碱基不同的列。核心 SNP 是在所有菌株中都存在（无空位）的 SNP 位点。
线程数	同时使用的处理器核心数；线程越多，大多数步骤越快。

2. 如何安装 EasyCGTree?

2.1 下载

从 **EasyCGTree5** 仓库的 **Releases** 页面可获取能直接运行的图形界面（GUI）软件，GitHub（<https://github.com/zdf1987/EasyCGTree5/releases>）和 Gitee（<https://gitee.com/zdf1987/EasyCGTree5/releases>，中国大陆用户推荐）均可下载。请下载与操作系统对应的软件包：

操作系统	软件包	图形界面程序
Windows 10/11（64 位）	EasyCGTree5-Windows-x64.zip	EasyCGTree_GUI.exe
Linux（64 位，glibc 2.35 及以上）	EasyCGTree5-Linux-x64.tar.gz	EasyCGTree_GUI
macOS 11 及以上，Apple 芯片（M1、M2 等）	EasyCGTree5-macOS-arm64.zip	EasyCGTree_GUI.app
macOS 11 及以上，Intel 芯片	EasyCGTree5-macOS-x64.zip	EasyCGTree_GUI.app

将软件包解压到一个路径中不含空格和中文字符的文件夹（如 Windows 下的 D:\EasyCGTree5，Linux 和 macOS 下的 ~/EasyCGTree5）。EasyCGTree 本身无需安装，系统安装 Perl 环境的情况下，便可正常使用。本手册将解压得到的文件夹称为 **EasyCGTree** 的“主目录”。

2.2 软件包内容

```

EasyCGTree5/
  EasyCGTree_GUI(.exe/.app)  图形界面（第 4 节）
  EasyCGTree.pl              主程序（第 5 节）
  EasyCGTree_SNP.pl          SNP 与 SNP 树分析脚本（第 7.1 节）
  EasyCGTree_SpecificSNP.pl  特异 SNP 分析脚本（第 7.2 节）
  BuildHMM.pl                构建 profile HMM 的脚本（第 7.3 节）
  Gene_Prevelence.pl         基因分布统计分析脚本（第 7.4 节）
  bin/                       第三方程序、tree_app-options.txt
  HMM/                       仅含 README.txt；HMM 集需单独下载（第 3.2 节）

```

2.3 Perl 及 EasyCGTree 调用的程序

EasyCGTree 的脚本由 Perl 编写，只使用 Perl 的核心模块。Linux 和 macOS 系统自带 Perl（要求 5.14 及以上）。Windows 用户需要安装 Perl，例如 Strawberry Perl (<https://strawberryperl.com/>)；一般情况下安装时程序会把 Perl 加入系统路径，EasyCGTree_GUI 会自动找到它。

EasyCGTree 调用的其他程序均已包含在各软件包的 'bin' 文件夹中：

- 1) HMMER^[1] (v3.4) : <http://hmmer.org/>
- 2) Prodigal^[3] (v2.6.3) : <https://github.com/hyatt/Prodigal>
- 3) MUSCLE^[4] (v5.3) : <https://www.drive5.com/muscle/>
- 4) trimAl^[5] (v1.5.1) : <http://trimal.cgenomics.org/>
- 5) FastTree^[6] (v2.2, 多线程版 FastTreeMP) : <https://morgannprice.github.io/fasttree/>
- 6) IQ-TREE^[7] (v3.1.4) : <https://iqtree.github.io/>
- 7) ASTRAL (ASTER v1.25 中的 wASTRAL^[8], 文件名为 astral-weighted) : <https://github.com/chaoszhong/ASTER>

Linux 和 macOS：如果 'bin' 中的程序无法启动（提示 'Permission denied'），请在 EasyCGTree 主目录中运行 `chmod +x bin/*` 赋予执行权限。macOS 还可能拦截从网上下载的程序，请在 EasyCGTree 主目录中运行一次 `xattr -dr com.apple.quarantine .`（见第 9 节）。

有经验的用户可以替换为其他版本的程序：以相同的文件名复制到 'bin' 中，或在 EasyCGTree_GUI 中设置其路径（设置 → 路径与程序，第 4.6 节）。

2.4 首次启动

双击 **EasyCGTree_GUI** 即可启动（Linux 下也可在终端中运行 `./EasyCGTree_GUI`）。EasyCGTree_GUI 会在其所在文件夹中自动找到各脚本、'bin' 和 'HMM'。然后选择 **帮助** → **检查安装**：程序会检测 Perl、五个脚本、'bin' 中的每个程序（及其版本）和各 HMM 集，并列出现存的问题和解决提示。

首次运行前，请至少将默认的 HMM 集 'bac120.hmm' 下载到 'HMM' 文件夹中（第 3.2 节）。

Windows：首次启动时 SmartScreen 可能提示未知程序（点击“更多信息”→“仍要运行”）。macOS：该程序未经 Apple 签名，首次启动时请右键点击 EasyCGTree_GUI.app 并选择“打开”。

2.5 从源代码运行或编译 EasyCGTree_GUI（可选）

软件包中的 EasyCGTree_GUI 是可直接运行的程序。如果希望使用源代码（例如下载的编译程序无法正常运行），可以用 Python 运行，或自行编译成程序。源代码（EasyCGTree_GUI.py）和编译脚本（build 文件夹）均可在上述仓库中下载。

用 Python 运行

需要 Python 3.9 或更高版本。先安装一次 Qt 库 PySide6，然后运行 EasyCGTree_GUI.py（将其放在 EasyCGTree 主目录中，与 EasyCGTree.pl 放在一起）：

```
$ python3 -m pip install PySide6
$ python3 EasyCGTree_GUI.py          (Windows: py EasyCGTree_GUI.py)
```

编译成程序

程序用 PyInstaller 编译。**程序只能在其目标操作系统上编译**（Windows 程序须在 Windows 上编译，macOS 程序须在 Mac 上编译）。在 build 文件夹中运行对应系统的脚本即可；编译时需要 Python 和网络

系统	命令	结果
Windows	双击 build_windows.bat	build\dist\EasyCGTree_GUI.exe

系统	命令	结果
macOS	bash build_macos.sh	build/dist/EasyCGTree_GUI.app
Linux	bash build_linux.sh	build/dist/EasyCGTree_GUI

每个 build 脚本都会在一个独立环境（.venv）中安装 PySide6 和 PyInstaller，并运行类似下面的命令：

```
pyinstaller --onefile --windowed --name EasyCGTree_GUI ../EasyCGTree_GUI.py
```

将编译结果复制到 EasyCGTree 主目录中即可。在 GitHub 上，仓库中的 .github/workflows/build-gui.yml 工作流可一次编译出所有系统的程序，build-release.yml 则可生成完整的软件包（见 build/README_BUILD.txt）。

3. 输入数据

只需 FASTA 格式的基因组数据（三类数据混合或其一：**CDS 蛋白序列、CDS 核酸序列、基因组 DNA 序列**）即可运行 EasyCGTree；如需使用自定义基因集进行同源检索，则还需准备相应的基因簇，并提前使用 BuildHMM.pl 构建 HMM。

3.1 基因组数据（FASTA 格式）

将基因组数据放在同一个文件夹中。EasyCGTree 会判断每个文件的序列类型，必要的时候使用 **Prodigal 预测 DNA 序列中的 CDS**。FASTA 文件需为未压缩格式。文件名和序列（空格、特殊字符、小写序列等）会被自动处理：**去掉扩展名的文件名即为树中各末端的标签**。在 EasyCGTree_GUI 中点击“检查输入”（或使用 -dry_run），可在运行前查看文件将如何分组和命名。

当用户提供 CDS 序列时，处理方式如下：

- NCBI 来源的同一组装的含 locus_tag 的蛋白文件（translated_cds.faa）+ CDS 核酸文件（cds_from_genomic.fna）（文件名中需含组装编号，如 GCF_000009925.1_ASM992v1...）：按 locus_tag 配对，两者均直接使用；如果能配对的蛋白不足 90%，说明两个文件可能不属于同一个基因组，程序会报错停止，请检查文件。这些基因组以组装编号命名（如 GCF-000009925-1）。
- 只有 CDS 蛋白序列文件：直接使用，但无法进行核酸序列相关的分析。只有 NCBI 的 CDS 核酸序列（序列名中含 [locus_tag=...], 如 cds_from_genomic.fna）：将 CDS 翻译为蛋白进行分析（遗传密码表 11）。
- 如果同一组装同时提供了基因组（genomic.fna）和 NCBI 的 CDS 序列，则优先使用注释文件（CDS 序列），忽略基因组文件。

其他来源的成对数据（蛋白和核酸序列）难以进行配对核验，每个文件都会被当作一个独立的基因组；序列名中不含 locus_tag 的 CDS 核酸序列会被当作基因组 DNA，由 Prodigal 重新预测 CDS。因此，非 NCBI 来源的数据，每个基因组请只提供一个文件（如基因组 DNA 序列）。

基于核酸序列建树（-seq nucl）和 SNP 分析（第 7 节）要求所有基因组均为 DNA 序列（基因组或 CDS 核酸序列文件）。

3.2 Profile HMM

构建 profile HMM 所用的基因集，决定了从蛋白质组中提取哪些基因来构建核心基因树。如何确定目标数据集的核心基因？最好的办法是先进行泛基因组分析。但如果只是想得到一棵核心基因树，泛基因组分析并不是最佳选择，采用前人研究或公共数据库中的核心基因集可能更方便。

EasyCGTree 提供若干预先构建的核心基因集 profile HMM，称为 profile HMM 数据库（PHD）。由于 HMM 文件较大（合计约 220 MB），且大多数用户只会用到其中少数几个，程序包中不包含 HMM 集：

程序包的 'HMM' 文件夹中只有 'README.txt'。请从仓库的 'HMM' 文件夹中单独下载所需的 HMM 集，保存到 EasyCGTree 的 'HMM' 文件夹中，不要修改文件名：

GitHub: <https://github.com/zdf1987/EasyCGTree5/tree/main/HMM>

Gitee: <https://gitee.com/zdf1987/EasyCGTree5/tree/main/HMM> (中国大陆用户推荐)

下载单个文件：在仓库的 'HMM' 文件夹中打开该文件，点击 'Download raw file' (GitHub) 或 “下载” (Gitee)；在 EasyCGTree_GUI 中，帮助 → 在线下载 HMM 集 可直接打开这些页面。**默认的 HMM 集为 bac120**：使用默认设置运行前，请先下载 'bac120.hmm'。如果缺少所需的 HMM 集，EasyCGTree 和 EasyCGTree_GUI 会停止运行，并提示查看 'HMM/README.txt' 和在线仓库。可用的 HMM 集如下（详细说明和参考文献见 'HMM/README.txt'）：

类群	基因集 (-hmm)	说明
原核生物	rp1	16 个普遍存在的核糖体蛋白基因（18 个结构域）
	rp2	23 个普遍存在的核糖体蛋白基因（27 个结构域）
细菌	bac120	细菌域中普遍存在的 120 个基因（默认）
	essential	107 个必需的单拷贝核心基因
	ubcg1 / ubcg2	92 / 81 个细菌核心基因（UBCG）
	bac52	52 个普遍存在的核糖体蛋白基因
古菌	ar122	古菌域中普遍存在的 122 个基因
	uacg	古菌域中普遍存在的 128 个基因
	ar53	53 个普遍存在的核糖体蛋白基因
其他	ery288 / rhodo268 / spi269	<i>Erythrobacteraceae</i> / <i>Rhodobacteraceae</i> / <i>Spirosomaceae</i> 的核心基因
	CKC20	<i>Corynebacterium kroppenstedtii</i> 复合群的 20 个核心基因
	AXT	虾青素合成的 5 个关键基因

PHD 可以扩展和自定义：用户提供的基因集（以基因簇形式准备）可用于构建 profile HMM (EasyCGTree_GUI 的“HMM 构建”页面，或 BuildHMM.pl, 第 7.3 节)。也可直接使用其他位置的 .hmm 文件。

4. 使用图形界面运行 EasyCGTree

4.1 主窗口

EasyCGTree_GUI 有三个标签页：主流程（对应 EasyCGTree.pl 和 Gene_Prevelence.pl）、SNP 分析（EasyCGTree_SNP.pl 和 EasyCGTree_SpecificSNP.pl）以及 HMM 构建（BuildHMM.pl）。各标签页布局相同（图 1）：

- 参数**（左侧）：先是全局设置，然后按运行顺序排列各步骤。所选任务用不到的选项会变灰；点击选项旁的“?”可查看说明。
- 状态和文件**（右侧）：“输出”和“输入”按钮可在输出文件夹与输入文件夹之间切换文件视图。选择输出文件夹时，状态栏显示已完成的步骤（预测、HMM 检索、筛选、比对、树）；选择输入文件夹时，显示各基因组、序列类型以及序列数和总长度。双击可打开文件夹、表格（在界面中显示）和其他文件。

- c. **命令行**（下方）：点击“运行”时将执行的命令。“简洁版”省略默认值，“完整版”显示全部参数；点击“复制”可复制到终端中使用。
- d. **运行日志**（下方）：运行中脚本的输出信息。“停止”可结束运行，包括由其启动的所有程序。




图1 EasyCGTree_GUI 主窗口

语言（英文/中文）在 **设置** → **语言** 中选择。路径与程序、语言和窗口大小会保留到下次启动；分析参数每次启动时恢复为默认值（可通过 **文件** → **保存参数/载入参数** 保存和载入）。

4.2 主流程：快速开始

- 1) 点击 **输入文件夹** 旁的“浏览...”，选择存放基因组数据的文件夹（第 3.1 节）。
- 2) 可选：选择 **输出文件夹**；默认情况下结果写入输入文件夹所在的上级文件夹。
- 3) 点击 **运行**。

使用默认设置时，会基于蛋白序列、用 FastTree 构建 bac120 基因的超矩阵树（如 myGenomes.bac120.119.supermatrix.fasttree.tree，第 6 节）。点击“检查输入”可在不运行任何程序的情况下，查看输入文件将如何分组和命名。

4.3 主流程：任务与参数

任务：可勾选 1 predict、2 hmmsearch、3 refine、4 alignment 和 5 tree_infer 五个任务（图 2）。任务必须连续：勾选两个任务时，中间的任务会被自动勾选。五个全选即为完整运行（'all'）；否则每个任务生成一条命令，依次运行。如果已存在用相同输入文件和设置得到的 CDS 预测结果，会显示黄色提示并自动取消勾选“predict”，直接使用已有的预测结果；关闭提示后才能重新勾选“predict”。

其余参数与 EasyCGTree.pl 的参数一一对应（第 5.2 节），并按步骤分组：1. CDS 预测（序列类型、保留 CDS 核酸序列），2. HMM 检索（HMM 集、E 值），3. 筛选（基因组阈值和基因阈值），4. 比对与修剪（trimAl 方法），5. 建树（方法和程序）。线程数最大为本机 CPU 核心数。

基因分布汇总：勾选“运行后汇总”会在主流程结束后运行 Gene_Prevelence.pl；运行内容选择“仅基因分布汇总”时，只统计基因的分布情况（第 7.4 节）。

4.4 SNP 分析

该页面对输入文件夹中的基因组最多运行三个环节（所有基因组必须为 DNA 序列）：

1) **SNP 提取**（EasyCGTree_SNP.pl）：如果缺少核心基因的核酸比对，会先以 '-seq nucl' 运行所需的 EasyCGTree 任务。页面中的 EasyCGTree 参数会根据上一次运行的记录（或默认值）自动填入。

2) **SNP 建树**：使用 IQ-TREE 或 FastTree。

3) **菌株与分支特异 SNP**（EasyCGTree_SpecificSNP.pl）：在 SNP 树或其他树（“其他树文件”，如超矩阵树；须为 Newick 格式，菌株名与 SNP 比对中的完全一致）上统计。指定其他树后，不再需要第 2 步，第 1 步只在需要时运行。解读分支特异 SNP 时，树必须正确定根；请在“外群”中指定外群菌株（见第 7.2 节）。

忽略的菌株、参考菌株和外群可从基因组列表中选择（“选择...”）。如果设置与上一次运行不同，下方会提示将从哪个 EasyCGTree 步骤重新运行及原因。同名的结果文件不会被覆盖，而是改名为 <文件名>.<日期>.bak。

4.5 HMM 构建

选择 **基因家族文件夹**（每个基因家族一个蛋白序列 FASTA 文件，如 EasyCGTree 运行产生的 'TEM4_GeneCluster' 文件夹），点击“运行”。新的 HMM 集以“HMM 集名称”中的名称（根据文件夹名自动填入）写入 'HMM' 文件夹，随后即可在其他页面中使用。勾选“已比对”时，已比对好的基因家族不会再次比对。

4.6 设置

a. **路径与程序**：EasyCGTree 主目录、'bin' 目录、Perl 以及各程序的路径。此处设置的程序会替代 'bin' 中的同名程序（如安装在其他位置的 IQ-TREE）。

b. **检查安装**（“帮助”菜单）：检测 Perl、各脚本、各程序和 HMM 集。

c. **在线下载 HMM 集**（“帮助”菜单）：打开 GitHub 或 Gitee 上仓库的 'HMM' 文件夹，或本地的 'HMM' 文件夹。

d. **建树程序命令行**：编辑 'bin/tree_app-options.txt'（IQ-TREE、FastTree 和 ASTRAL 的参数，第 5.4 节）。

5. 在命令行中运行 EasyCGTree

5.1 用法

EasyCGTree_GUI 的所有功能也可在命令行中使用（Windows 下的 **cmd.exe** 或 PowerShell，Linux 和 macOS 下的终端）。脚本可在任意目录下调用，输入文件夹也可位于任意位置。假设 EasyCGTree 解压在 D:\EasyCGTree5（Windows）或 ~/EasyCGTree5（Linux/macOS），基因组位于文件夹 myGenomes 中：

```
> perl D:\EasyCGTree5\EasyCGTree.pl -input D:\data\myGenomes
```

```
$ perl ~/EasyCGTree5/EasyCGTree.pl -input ~/data/myGenomes -tree st -tree_app iqtree -  
thread 8
```

运行结束后，会在输入文件夹旁（或 `-outdir` 中）得到一棵以输入文件夹命名的 Newick 格式的树（如 `myGenomes.bac120.119.supermatrix.fasttree.tree`），以及日志文件和工作目录 `myGenomes_TEM`（第 6 节）。EasyCGTree_GUI 中显示的命令（第 4.1 节）也可以复制后以同样方式运行。

注意：Windows 用 `\` 分隔文件夹，Linux 和 macOS 用 `/`。含空格的路径需加引号。

5.2 EasyCGTree.pl 的参数（顺序不限）

-input <String> （唯一必需的参数）

包含所有基因组数据的输入文件夹（第 3.1 节）。

-outdir <String>

所有结果（工作目录 `'<input>_TEM'`、树、日志文件）的输出文件夹。[默认：输入文件夹所在的上上级文件夹]

后续任务必须使用与前面任务相同的 `'-outdir'`，否则会找不到前面任务的结果：单独运行后续任务时会报错，完整运行则会在新位置重新分析。

-task <String, 'all', 'predict', 'hmmsearch', 'refine', 'alignment', 'tree_infer'>

运行模式（图 2）。[默认：all]

每个任务使用 `'<input>_TEM'` 中前面任务的结果；各任务的设置会记录在其中，后续任务会检查设置是否一致（如是否为同一个 HMM 集）。




图 2 EasyCGTree 完整运行的流程图

-seq <String, 'prot', 'nucl'>

建树所用的序列类型（氨基酸或核酸）。[默认： prot]

'nucl' 要求所有基因组均为 DNA 序列。

-keep_CDS_nucl

同时保留以 DNA 形式提供的基因组的 CDS 核酸序列（如以后构建核酸比对时使用）。使用 '-seq nucl' 时无需设置。

-hmm <String, 'bac120', 'rp1' 等, 或 .hmm 文件>

用于检索基因的 profile HMM（第 3.2 节）。[默认： bac120]

-evaluate <Real, 10..0>

HMM 检索时保留命中结果的 E 值。[默认： 1e-10]

-genome_cutoff <Decimal, 0..1>

剔除低质量基因组的阈值。[默认： 0.8]

-gene_cutoff <Decimal, 0..1>

剔除低检出率基因的阈值。[默认：0.8]

使用 '-tree cs' 时总是使用 1；使用 '-tree st' 时建议设为 1。

-trim <String, 'gappyout', 'strict', 'strictplus', 'nogaps'>

trimAl 修剪比对的标准。[默认：strict]

'nogaps' 去除所有含空位的列；修剪后不剩任何列的基因会被跳过。

-tree <String, 'sm', 'st', 'cs'>

建树方法。[默认：sm]

sm：超矩阵（串联比对）；st：超树（用 ASTRAL 整合基因树）；cs：基因树的多数一致树（由 IQ-TREE 生成）。

-tree_app <String, 'fasttree', 'iqtree'>

建树所用的程序。[默认：fasttree]

-thread <Int>

HMMER、MUSCLE、FastTree、IQ-TREE 和 ASTRAL 使用的线程数。[默认：4]

如果大于 CPU 核心数，则使用核心数。

-dry_run

只检查输入文件夹：显示输入文件将如何分组和命名，不重命名文件，也不运行任何程序。

-help

显示帮助信息。

如何选择参数？

a. **先用默认设置。** 默认设置（bac120、蛋白序列、超矩阵、FastTree）对大多数细菌数据都能得到较好的树；古菌请选择古菌的 HMM 集（如 ar122 或 ar53）。

b. **蛋白还是核酸？** 蛋白序列（-seq prot）适合属、科及更高分类阶元。亲缘关系很近的菌株（如同一个种内），蛋白序列差异太少，请使用 -seq nucl 或 SNP 分析（第 7.1 节）。

c. **FastTree 还是 IQ-TREE？** FastTree 速度快，适合初步查看或大数据集。IQ-TREE 会选择最佳替代模型并计算超快自举支持率，速度较慢、内存需求较大。

d. **超矩阵、超树还是一致树？** 超矩阵（sm）通常最可靠、速度最快。超树（st）和一致树（cs）需为每个基因建树，耗时较长；可用来考察各基因反映的关系是否一致（如一致树的数值低说明基因之间存在冲突）。

5.3 关于 '-genome_cutoff' 和 '-gene_cutoff' 的更多说明

这两个参数可能让一些用户感到困惑。大多数情况下保持默认即可，尤其是基因组数量有限（<30）且均为完整基因组时。但如果使用的基因组很多，必然会有一些基因在部分基因组中检测不到，共有基因的数量随之减少。事实上，GTDB（Genome Taxonomy Database, <https://gtdb.ecogenomic.org>）代表性数据库中的许多基因组，其 bac120/ar122 基因集并不完整。共有基因的数量与基因组的数量之间需要权衡。

这两个参数通过剔除低检出率的基因和低质量的基因组来平衡这一矛盾。用户需要注意，这两个参数决定了输入基因组质量的下限（入选的基因集由入选的基因组决定）。如果基因组质量都很高，降低阈值并无意义。例如，如果所有基因组都含有完整的 bac120/ar122 基因集，无论阈值设为多少（0.5–1），都会用全部 120/122 个基因建树。Gene_Prevelence.pl（第 7.4 节）可预览在给定阈值下有多少基因组和基因能通过筛选。

5.4 建树程序的参数

IQ-TREE、FastTree 和 ASTRAL 的命令行可在 'bin/tree_app-options.txt' 中修改（或在 EasyCGTree_GUI 中：设置 → 建树程序命令行），例如 IQ-TREE Command-line=iqtree3 -B 1000 表示进行 1000 次超快自举检验。输入比对文件和线程数由 EasyCGTree 自动添加。

6. 输出文件

假设输入文件夹为 'myGenomes'。

1) Newick 格式的系统发育树。可用 [FigTree](#)、[MEGA](#)、[iTOL](#) 等软件查看。最终树文件的命名如下：

```
myGenomes.bac120.119.supermatrix.fasttree.tree
(1)      (2)      (3)      (4)      (5)
```

(1) 输入文件夹名 (-input)；(2) 所用基因集 (-hmm)；(3) 用于建树的基因数；(4) 建树方法 (-tree: supermatrix、supertree 或 consensus)；(5) 所用程序 (-tree_app: fasttree 或 iqtree)。如果已存在同名的树文件，旧文件会被改名为 '<文件名>.<日期>.bak'，而不会被覆盖。

2) 日志文件（如 myGenomes.bac120.sm.fasttree_2026-10-09-10-30.log），以输入文件夹、HMM、建树方法、程序和开始时间命名（'-task predict' 时为 myGenomes.predict_<时间>.log）。其中记录了运行的详细信息，如哪些基因和基因组被保留或删除、IQ-TREE 选择的替代模型等。

3) 工作目录 (myGenomes_TEM)，以输入文件夹命名并以 '_TEM' 结尾。其中的文件和文件夹名称对所有运行都相同：

- a. **TEM0_CDS**：各基因组的蛋白序列 (.faa) 以及需要时的 CDS 核酸序列 (.fnn)，复制自输入文件或由 Prodigal 预测。
- b. **TEM1_HMMsearch_out**：各基因组的 HMM 检索结果。
- c. **TEM2_HMMsearch_outS**：筛选后的 HMM 检索结果：每个基因的最佳命中（满足 E 值和得分阈值）。
- d. **TEM3_GeneSeqs**：从各基因组中提取的基因序列。
- e. **TEM4_GeneCluster**：每个基因一个文件，包含所有基因组中的同源序列。这些文件可直接用于构建 profile HMM（第 7.3 节）。
- f. **TEM5_Alignment** 和 **TEM6_AlnTrimmed**：MUSCLE 生成的比对，以及经 trimAl 修剪后的比对。
- g. **TEM7_GeneTrees**：基因树 (st 和 cs 方法)；**intree**：汇总所有基因树的文件，供 ASTRAL 或 IQ-TREE 使用。
- h. **<名称>.concatenation.fas**：入选基因的串联比对 (sm 方法)，也可用于 RAxML、FastME 等其他软件。
- i. **TEM8_SNP**：EasyCGTree_SNP.pl 的工作文件。
- j. **Genome_SeqType.txt**（各基因组的输入类型和文件）、**HMMInfo.txt**（各 HMM 的基因及长度）、**GenomeGeneScreened.txt**（筛选后的基因组和基因）、**trimAl_Details.txt**（修剪前后的比对长度）、**EasyCGTree_record.txt**（已运行任务的设置和时间，请勿编辑）。

7. 其他脚本

以下四个脚本的用法与 EasyCGTree.pl 类似（EasyCGTree_GUI 也会调用它们）。每个脚本都会写日志文件；如果缺少所需的 EasyCGTree 结果，会自动运行相应的任务。通用参数 -outdir、-thread 和 -help 的含义与 EasyCGTree.pl 相同。

7.1 EasyCGTree_SNP.pl

从核心基因的串联核酸比对中提取 SNP，并构建 SNP 树。如果缺少核酸比对，或比对所用的设置与给定的不同，会以 '-seq nucl' 运行所需的 EasyCGTree 任务。

```
> perl EasyCGTree_SNP.pl -input myGenomes [options]
```

-input <String> (必需)

EasyCGTree 使用（或将要使用）的输入文件夹。所有基因组必须为 DNA 序列。

-ignore <String>

检测 SNP 位点时忽略的菌株（以逗号分隔的名称，或每行一个名称的文件）。这些菌株仍保留在 SNP 比对和树中，但仅因它们而变化的位点不算作 SNP。

-max_missing <Decimal, 0..1>

SNP 位点上允许为空位或模糊碱基的菌株的最大比例。[默认：0，即核心 SNP]

-aln <String, 'trimmed', 'original'>

所用的比对：经 trimAl 修剪的，或修剪前的。[默认：trimmed]

-ref <String>

参考基因组：同时给出 SNP 在其 CDS 中的位置和密码子位置。

-tree_app <String, 'iqtree', 'fasttree'> / -no_tree

构建 SNP 树的程序 [默认：iqtree]；'-no_tree'：只提取 SNP。

-asc <String, 'fconst', 'lewis'>

IQ-TREE 对只使用变异位点的校正方式。[默认：fconst]

-hmm、-evaluate、-gene_cutoff、-genome_cutoff、-trim

需要运行 EasyCGTree 任务时传递给 EasyCGTree [默认：上一次运行的设置]。

输出： <input>.<hmm>.<genes>.snp.fas（SNP 比对）、.snp_positions.txt（各 SNP 的位置）、.snp_genes.txt（各基因的 SNP）、.snp_distance.txt（两两之间的 SNP 距离）和 .snp.<tree_app>.tree（SNP 树）。

7.2 EasyCGTree_SpecificSNP.pl

在树上统计菌株和分支特异的 SNP：每个菌株名后加上 '_N'（N 为该菌株特有的 SNP 数），每个分支标注为 'N/S'（N 为该分支特有的 SNP 数，S 为支持率）。使用 EasyCGTree_SNP.pl 的 SNP 结果（如缺少则先运行它）。

```
> perl EasyCGTree_SpecificSNP.pl -input myGenomes -outgroup strainA,strainB [options]
```

-tree_app <String, 'iqtree', 'fasttree'>

要标注的 SNP 树的构建软件。[默认：iqtree]

-tree <String>

改为标注其他树（如 EasyCGTree 的超矩阵树）：Newick 格式，菌株名须与 SNP 比对中的完全一致。树应事先按需要定好根，或用 '-outgroup' 指定外群。

-outgroup <String>

用这些菌株给树定根（以逗号分隔；须构成一个分支）。

-mode <String, 'exclusive', 'strict'>

exclusive：该组的所有菌株共有一个其他菌株都没有的碱基 [默认]；strict：此外其他所有菌株也共有同一个碱基（只使用无缺失数据的位点；与定根无关）。

输出：<out>.tree（标注特异 SNP 数的树）、<out>.clade_ID.tree（以分支编号为标签）、<out>.positions.txt（各特异 SNP）和 <out>.groups.txt（各菌株和分支的支持率、SNP 数和成员）。

为什么定根和外群很重要

分支特异 SNP 是指一个分支内所有菌株共有、而其他菌株都没有的碱基。但哪些菌株构成一个“分支”，取决于树的根在哪里。IQ-TREE 和 FastTree 构建的树是**无根树**：只表示每条枝把菌株分成哪两部分文件中写出的根是任意的。每条枝都把菌株分为两侧，被称为“分支”的是远离根的那一侧。如果根的位置不对，一个分支可能被“里外颠倒”（一个类群的特异 SNP 被算到树的其余部分上），还会出现实际上并不存在的分支。**因此，在解读分支特异 SNP 之前，必须先给树正确定根。**

如何选择外群： 选用一个或几个肯定位于目标类群之外、但亲缘关系又不太远的菌株，例如同属近缘种的菌株。外群菌株要从一开始就放在输入文件夹中，因为它们必须出现在比对和 SNP 数据中。外群菌株在树中必须构成一个分支，否则 EasyCGTree_SpecificSNP.pl 会停止并给出提示。注意：

- 根处的两条枝在无根树中其实是同一条枝，因此把外群与其他菌株分开的 SNP 会同时标在这两条枝上。
- 外群太远会增加大量 SNP 位点并减少核心位点（比对中空位增多）；通常选择较近的外群更好。
- 如果把外群菌株同时设为“忽略的菌株”（第 7.1 节），仅因外群而变化的位点不算作 SNP；内群中的计数只基于内群本身，但根处的枝上 SNP 会变少。
- 不指定外群时，按树文件中原有的根使用。'strict' 模式与定根无关（只取决于枝），但其数值仍标在每条枝的一侧。

使用其他树（-tree）时，该树应事先按需要定好根（如在看树软件中以外群定根），或用 -outgroup 指定外群，由 EasyCGTree_SpecificSNP.pl 重新定根。

7.3 BuildHMM.pl

用自定义的基因簇（蛋白序列，每个基因家族一个 FASTA 文件）构建 profile HMM 数据库。数据库写入 PHD（'HMM' 文件夹），之后即可用 '-hmm <名称>' 使用。

```
> perl BuildHMM.pl -gc Dir_name [options]
```

-gc <String>（必需）

FASTA 格式基因簇的输入文件夹。文件名（去掉扩展名）即为基因名。

-name <String>

HMM 数据库的名称。[默认：输入文件夹的名称]

-force

覆盖已存在的同名数据文件。

-aln

提示基因簇已经比对好，BuildHMM.pl 不再进行比对。

-super5 <Int>

序列数不少于该值的基因家族使用 'muscle -super5'（更快）比对。[默认：1000]

输出：HMM/<name>.hmm、<gc>.BuildHMM_summary.txt（各基因家族的序列数、比对长度和 HMM 长度）以及工作目录 <gc>_BuildHMM_TEM。

7.4 Gene_Prevelence.pl

基于 EasyCGTree 的 HMM 检索结果（如缺少，则用 EasyCGTree.pl 进行检索），统计基因集中各基因在各基因组中的分布情况，并预览在 EasyCGTree 的阈值下有多少基因组和基因能通过筛选。

```
> perl Gene_Prevelence.pl -input myGenomes [options]
```

-input <String> (必需)

输入数据文件夹。

-hmm <String> / -evalue <Real>

Profile HMM 和 E 值 [默认: 已有 HMM 检索所用的选择]。

-force

如果已有的检索使用的是其他 HMM, 则重新检索 (会替换 '<input>_TEM' 中后续步骤的结果)。

-genome_cutoff / -gene_cutoff <Decimal>

用于预览、评估所用阈值筛选得到的结果。[默认: 0.8]

输出 (<input>.<hmm>.*): gene_prevalence.txt (各基因组中检出的蛋白编号总表)、gene_copies.txt (拷贝数)、gene_summary.txt (按各基因统计)、genome_summary.txt (按各基因组统计) 以及 shared_hits.txt。

在部分基因组中, 某些基因的最佳匹配可能是同一个蛋白序列 (如: 同一蛋白的两个结构域在有些菌株中以一个 CDS 的形式出现, 而在另一些菌株中是两个 CDS; 旁系同源基因在不同基因组中存在数量差异等)。此时 EasyCGTree 会重复使用该蛋白, 使这些基因的权重发生变化, 进而带来遗传信号的干扰。这种情况较为复杂, 目前还没有高效、严谨的解决办法。一般来说, 广泛应用的基因集 (如 bac120) 中的基因发生这种情况的概率很低 (输入数据所属类群的亲缘关系也是重要因素), 且基因数量较多时, 这些干扰信号对结果的影响不大。这些蛋白在表格中以 '*' 标注, shared_hits.txt 中列出了相关的基因对, 供用户参考。

8. 硬件要求

输入数据量不大时, 普通个人电脑即可运行 EasyCGTree, 因为 HMMER、MUSCLE 和 FastTree 速度很快, 且在所有系统上都支持多线程。运行速度取决于输入数据的大小: 基因组少于 100 个时, 基于 bac120 的分析在个人电脑上几个小时内即可完成。数据量更大时, 建议使用高性能电脑或服务器。请注意, IQ-TREE 所需的时间和内存远多于 FastTree; 如果在个人电脑上用 IQ-TREE (-tree_app iqtree) 运行失败, 可改用 FastTree, 或使用性能更强的计算机。

9. 常见问题

1. EasyCGTree_GUI 提示找不到 Perl。

答: Windows 用户需要安装 Perl (第 2.3 节) 并重新启动 EasyCGTree_GUI, 或在“设置 → 路径与程序”中指定 perl.exe 的路径。

2. 提示 “The profile HMM 'bac120' was not found”。

答: HMM 集需单独下载 (第 3.2 节)。请从 GitHub 或 Gitee 上仓库的 'HMM' 文件夹下载 'bac120.hmm' (或所选的 HMM 集), 放入 EasyCGTree 的 'HMM' 文件夹。

3. 'bin' 中的程序无法启动 (Linux/macOS)。

答: 在 EasyCGTree 主目录中运行 `chmod +x bin/*`。在 macOS 上, 还需在该目录中运行一次 `xattr -dr com.apple.quarantine .`, 因为 macOS 会拦截从网上下载的程序。

4. 后续任务因已有结果而停止。

答：每个任务的设置都记录在 '`<input>_TEM/EasyCGTree_record.txt`' 中，后续任务必须使用相同的 HMM 集、阈值和 '`-outdir`'。请用新的设置重新运行前面的任务，或使用 '`-task all`'。

5. 无法读取用其他 HMMER 版本构建的 profile HMM。

答：HMMER 3.1 及以上版本构建的 HMM 无法被 HMMER 3.0 读取。EasyCGTree 5.0 使用 HMMER 3.4，可以读取所有版本的 HMM；如果在 'bin' 中换用了旧版程序，'hmmbuild' 和 'hmmsearch' 必须为同一版本。

6. 树上分支处的数值是什么意思？

答：它们是支持率（第 1.1 节）：FastTree 给出 SH 类局部支持率（0–1），IQ-TREE 使用 '`-B 1000`' 时给出超快自举值（0–100），一致树给出含该分支的基因树的百分比，ASTRAL 给出其自身的分支支持值。支持率低的分支需谨慎解读。

7. 树是如何定根的？

答：EasyCGTree 得到的树是无根树，看树软件显示的根是任意的。请在看树软件中用外群定根（如 FigTree 或 iTOL 中的“Reroot”），并在输入数据中加入合适的外群菌株（第 7.2 节）。

8. 能否在没有图形界面的服务器上使用 EasyCGTree？

答：可以。所有功能都可通过 Perl 脚本使用（第 5 节和第 7 节）。

10. 引用

Zhang Dao-Feng, He Wei, Shao Zongze, Ahmed Iftikhar, Zhang Yuqin, Li Wen-Jun & Zhao Zhe. EasyCGTree: a pipeline for prokaryotic phylogenomic analysis based on core gene sets. *BMC Bioinformatics* 2023 24:390. <https://doi.org/10.1186/s12859-023-05527-2>

11. 参考文献

1. Eddy SR. Accelerated profile HMM searches. *PLoS Comput Biol* 2011 7(10): e1002195.
2. Snel B, Huynen MA, Dutilh BE. Genome trees and the nature of genome evolution. *Annu Rev Microbiol* 2005 59: 191-209.
3. Hyatt D, Chen GL, LoCascio PF, et al. Prodigal: prokaryotic gene recognition and translation initiation site identification. *BMC Bioinformatics* 2010 11: 119.
4. Edgar RC. Muscle5: high-accuracy alignment ensembles enable unbiased assessments of sequence homology and phylogeny. *Nat Commun* 2022 13: 6968.
5. Capella-Gutiérrez S, Silla-Martínez JM, Gabaldón T. trimAl: a tool for automated alignment trimming in large-scale phylogenetic analyses. *Bioinformatics* 2009 25(15): 1972-1973.
6. Price MN, Dehal PS, Arkin AP. FastTree 2 - approximately maximum-likelihood trees for large alignments. *PLoS One* 2010 5(3): e9490.
7. Wong TKF, Ly-Trong N, Ren H, Demotte P, Baños H, Roger AJ, Susko E, Bielew C, De Maio N, Goldman N, Hahn MW, Dos Reis M, Vinh LS, Huttley G, Lanfear R, Minh BQ. IQ-TREE 3: phylogenomic inference software using complex evolutionary models. *Mol Biol Evol* 2026 43(5): msag117.
8. Zhang C, Mirarab S. Weighting by gene tree uncertainty improves accuracy of quartet-based species trees. *Mol Biol Evol* 2022 39(12): msac215.